

一带一路对中国和其他沿线国家的影响及政策分析

数据科学的视角

范皓年

邓睿哲

李润泽*

目录

1 概述	2
2 主要工作	2
2.1 数据模型	2
2.2 分析技术	2
2.3 程序技术	4
3 具体细节	5
3.1 环境	5
3.2 The Workflow	5
3.3 数据集说明	5
3.4 数据清洗	6
3.5 数据分析	7
3.6 数据可视化	7
4 总结	10
4.1 分析结果	10
4.2 不足和展望	11
参考文献	11

*名拼音序.

1 概述

2 主要工作

2.1 数据模型

我们的数据模型如图所示：

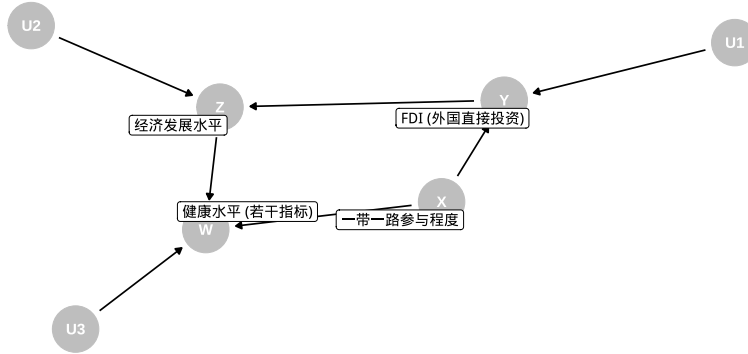


图 1: 数据模型示意图

此图在 R 语言中，用 **ggdag**^[1] 生成。是有向无环图 (Directed acyclic graph, DAG)，边代表因果作用^[2]。

在该模型中，我们假定一带一路不会以其他方式影响地区的经济发展水平（即不存在 $X \rightarrow Y$ 的线），从而 Y 是一个良好的替代变量。

2.2 分析技术

本项目主要利用到以下三种分析技术。首先注意到数据集中存在许多缺失数据^[3]。缺失数据的删除或填补需要用到一些技术。分析一带一路的影响，就是要分析某一事件发生后，某一值的变化情况。该值自身也存在着模型外因素导致的变化趋势，所以我们必须利用某些技术来去除这些因素的影响。于是，我们运用如下所述的双重差分和合成控制两种技术。

2.2.1 缺失数据填补

我们的数据集，正和许多类似的真实世界数据集一样，存在着许多缺失数据 NA。缺失数据的处理方式不外乎删除或填补。

- 对于我们的 investment 数据集，其缺失普遍存在，故我们采用填补的方法。
- 对于本次大赛提供的世界健康数据集，其缺失更有规律，即对于任意一个国家，缺失一个时间点的数据意味着缺失此前所有数据。恰当地选择时间范围，再删去个别几个缺失较大的国家¹，就在可以避免填补的同时保留大部分数据。因此，我们选择删去。

¹ 这些国家往往那时才成立，例如从母国中分裂出。




图 2: 缺失数据示意图

对于前者, 我们调用 R 包 **mice**^[4], 采用 linear regression with bootstrap 的方法进行缺失数据填补. 首先, 对数据进行 bootstrap 重抽样, 进行线性回归插值, 然后计算均值得到最后结果. 其中, 多元线性回归的步骤采用 Schafer 的算法^[5].

2.2.2 二重差分法

二重差分法 (Difference-in-Differences, DID) 是一种经典技术. 所谓二重差分, 就是先把实验组与对照组作差, 再对差作差分, 考察其随时间的变化情况. 换句话说, 此方法假定对于每个固定的 t , 存在一个固定的内禀的 μ . 具体来说, 就是以下模型^[6]

$$P_t^N = \mu + \frac{1}{J} \sum_{j=2}^{J+1} Y_{jt}^N$$

并用如下公式来估计.

$$\hat{P}_t^N = \frac{1}{T} \sum_{s=1}^T \left(Y_{1s}^N - \frac{1}{J} \sum_{j=2}^{J+1} Y_{js}^N \right) + \frac{1}{J} \sum_{j=2}^{J+1} Y_{jt}^N$$

2.2.3 合成控制法

合成控制法 (Synthetic Control) 是另一种经典技术. 不难发现, DID 所要求的条件过高, 在现实生活中一般并不成立. 举例来说, 实验组可能有其自身特点, 导致增长本来就比对照组快. 而所谓合成控制, 就是用对照组的数据“合成”出来一个虚拟的实验组, 然后应用到事件发生后的情况, 得到实验组的反事实数据. 具体来说, 就是以下模型^[7].

$$P_t^N = \sum_{j=2}^{J+1} w_j Y_{jt}^N, \text{ where } w \geq 0, \sum_{j=2}^{J+1} w_j = 1.$$

为了识别合成的权重 w , 我们需要一些假设, 在这里是结构冲击项 u_t 在同一时段内互不相关, 即:

$$E(u_i Y_{jt}^N) = 0, \text{ for } 2 \leq j \leq J+1.$$

于是就有估计

$$\hat{P}_t^N = \sum_{j=2}^{J+1} \hat{w}_j Y_{jt}^N.$$

而 w 的估计

$$\begin{aligned} \hat{w} = \arg \min_w \sum_{i=1}^T \left(Y_{1t}^N - \sum_{j=2}^{J+1} w_j Y_{jt}^N \right)^2, \\ \text{subject to } w \geq 0, \sum_{j=2}^{J+1} w_j = 1. \end{aligned}$$

此后，我们利用 Chernozhukov et al.^[8] 的方法分析 P 值和置信区间等信息.

2.3 程序技术

2.3.1 Non-standard evaluation, NSE

本项目使用了一种在 R 中非常重要的技术，即 Non-standard evaluation.^[9]

具体来说，让我们看一段代码：

```
### Using lazy evaluation to replicate a func along country list
repli <- function(fun) {
  ex <- substitute(fun)

  for (i in seq_along(country_list)) {
    # ...
    eval(ex, envir = globalenv())
  }
}

repli(placebo_specification_test())
```

R 采用 lazy evaluation，只有在真正用到 `fun` 的时候才会对其进行求值，其中 `fun` 的返回值并不必须良定。这在这里是重要的特性，因为一般的语言具有引用透明 (reference transparency) 的特点，会将 `fun` 的返回值作为 `repli` 的输入，这会对我们的目标造成不便。此处，`substitute` 将参数转变为 `promise`，而并不对其进行求值；在 `for` 循环内部，调用 `eval` 进行求值，以达到重复执行某个函数的目的。

3 具体细节

3.1 环境

3.1.1 R 环境

本项目的 R 部分使用如下环境生成²:

```
## R version 4.1.0 (2021-05-18)
## Platform: x86_64-pc-linux-gnu (64-bit)
## Running under: Ubuntu 20.04.2 LTS
##
## Locale:
##   LC_CTYPE=zh_CN.UTF-8      LC_NUMERIC=C
##   LC_TIME=zh_CN.UTF-8      LC_COLLATE=zh_CN.UTF-8
##   LC_MONETARY=zh_CN.UTF-8  LC_MESSAGES=zh_CN.UTF-8
##   LC_PAPER=zh_CN.UTF-8     LC_NAME=C
##   LC_ADDRESS=C             LC_TELEPHONE=C
##   LC_MEASUREMENT=zh_CN.UTF-8 LC_IDENTIFICATION=C
##
## Package version:
##   dplyr_1.0.6      ggdag_0.2.3      ggplot2_3.3.3    lubridate_1.7.10
##   mice_3.13.0     purrr_0.3.4     readr_1.4.0      showtext_0.9-2
##   stringr_1.4.0   tidyr_1.1.3     tidyverse_1.3.1  VIM_6.1.0
```

3.1.2 python 环境

本项目的 python 部分使用 python 3.8.8 生成，部分包版本号如下：

conda 4.10.1; pyecharts 1.9.0; numpy 1.20.1; json5 0.9.5; pandas 1.2.4; jupyterlab 3.0.14

3.2 The Workflow

根据 *R for Data Science*^[10]，数据分析的一般流程如下图所示。本项目也符合这种模式。

3.3 数据集说明

国际贸易数据 (/data/investment/FDI_untidy.csv) 下载自 CEIC 数据库。我们引用 CEIC 全球数据库中“实际利用的外国资本：按地区分类”和“对外直接投资：国别”两个数据集，逐条下载了中国在利用其他国家资

²部分依赖省略。

³This picture is from *R for Data Science*, released under [CC BY-NC-ND 3.0 US](https://creativecommons.org/licenses/by-nc-nd/3.0/us/).

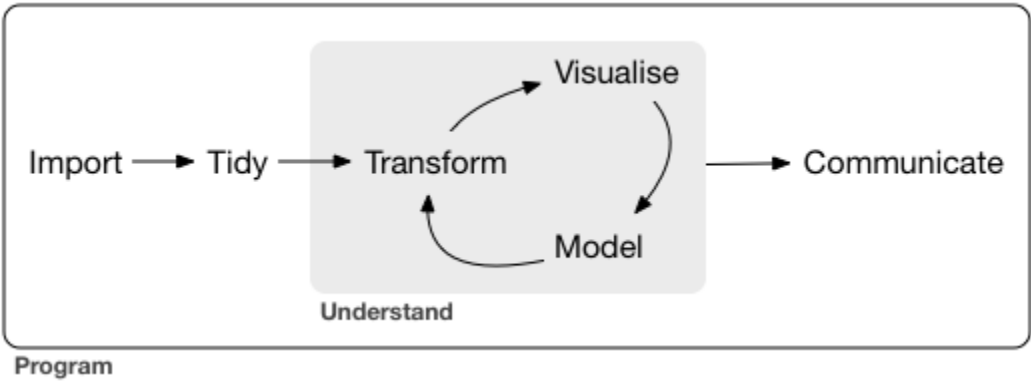


图 3: The Data Science Workflow³

本量（月度数据），和中国对其他国家的直接投资（月度数据）。CEIC 数据库覆盖的时间范围为 1985 年 12 月至 2021 年 4 月，每条数据均以月为统计单位，故为了数据的完整性，初步清洗时，以纵轴为月份（自 1985 年 12 月至 2021 年 4 月），横轴为统计指标（中国利用不同国家的资本，与对不同国家的直接投资），对数据进行了合成与排列。

其中，实际利用的外国资本分为直接投资和其他投资方式。直接投资包括中外合资，合资开发和独资企业，外资参股公司以及共同开发；其他投资方式包括补偿贸易和加工组装。数据来源为国家统计局和中华人民共和国商务部。该数据可反映外国对中国的投资。

对外直接投资指中国国内投资者以现金、实物、无形资产等方式在国外及港澳台地区设立、购买国（境）外企业，并以控制该企业的经营管理权为核心的经济活动。数据统计来源为中华人民共和国商务部。该数据可反映中国对外投资。

其他用到的数据集来自世界健康数据集，包括：

- under5MortalityRate.csv 数据集记录了 1962-2019 年不同国家 5 岁以下儿童死亡率（每千人的死亡人数）。我们认为，该指标反应了一国最基础的医疗水平状况。相比预期寿命，该指标更好地将研究标的限制在了基础卫生条件，如洁净水源、疫苗接种、家庭卫生条件等。而对于发展中国家，基础医疗状况和卫生水平的提高，才能最贴切地带来经济发展的动力。故在预期寿命之外，我们还专门将“5 岁以下儿童死亡率”作为研究指标。
- infantMortalityRate.csv 数据集记录了 1962-2019 年不同国家出生婴儿死亡率（每千人的死亡人数）。我们认为，相比 5 岁以下儿童死亡率，该指标更准确地反映了一国在生育保障上的医疗和健康水平。

3.4 数据清洗

虽然不为人所重视，数据清洗往往是数据分析工作中耗时最久的部分。^[11] 不仅如此，数据清洗的目标也往往不被人熟知。什么数据结构才算是整理好？幸运的是，Hadley Wickham 的文章^[12] 向我们提供了一种通俗易懂的解释：每行应该代表一个观察（observation），每列应该代表一个变量（variable）。根据此种原则，并利用其为此目的开发的 R 包 **tidyverse**^[13]，进行数据清洗。其部分步骤如下所示。

```

process <- function(raw_df) {
  simplified_df <- raw_df %>%
    filter(X1 %>% str_detect("^\\d")) %>%
    rename(时间 = X1)

  flipped_df <- simplified_df %>%
    pivot_longer(c(-时间), names_to = "observation", values_to = "val")

  stdize <- function(str) {
    str %>%
      str_replace(pattern = "(.*):(总计 | 一带一路)", replacement = "\\1/\\2/\\2") %>%
      str_replace(pattern = "::", replacement = ":") %>%
      str_replace(pattern = "(.*):(.* 洲):*(.*)", replacement = "\\1/\\2/\\3")
  }

  sep_df <- flipped_df %>%
    mutate(observation = observation %>% stdize()) %>%
    separate(col = "observation", into = c("type", "地区", "国家"), sep = "/")

  df <- sep_df %>% spread(key = "type", value = "val")
}

```

3.5 数据分析

数据建模和分析是传统上受重视的技术. 其主要内容[已经](#)详述, 这里不再赘述. 对各个国家分别进行的分析结果存储于本项目的 `results` (健康数据) 和 `results_invest` (投资数据) 文件夹中. 其中, `sens.csv` 描述了对测试进行安慰剂检验 (placebo test) 的情况, `p.noeff.csv` 描述了测试的 P 值, `ci.csv` 描述了结果的置信区间, `pdf` 文件绘制出了按国家分类的置信区间的情况.

3.6 数据可视化

本节说明项目中所用到的可视化相关工具、组件、流程。

3.6.1 可视化工具

项目将世界经济及其相关的数据, 展示在世界地图上, 考虑 Python 语言相对于 JavaScript 具有更好的数据处理能力, 我们使用基于 Apache Echarts^[14] 的 Pyecharts。

我们主要做了如下几个可视化工作：

- 将 2003 到 2019 年的中国对外直接投资总额表示在地图上
- 将世界健康数据集中预期寿命和 5 岁以下死亡率分性别表示在图中

我们从图中可以定性地看出中国外企对于一带一路沿线国家的投入，以及相应国家的经济水平、生活水平的优化。

3.6.2 文件结构

可视化相关的脚本以及输出结果全部储存在 `./visualization` 中。

```
visualization
├── README.md
├── data
│   ├── FDI_filled_m.csv
│   ├── FDI_useful.csv
│   ├── LE.csv
│   ├── UFMR_m.csv
│   ├── country_ce.json
│   ├── syno_dict.json
│   └── world_country.json
├── mytool.ipynb
├── obor_raw_plot
│   └── ...
├── wh_raw_plot
│   └── ...
├── out
│   ├── 五岁以下死亡率.html
│   ├── 外商直接投资情况-filled.html
│   ├── 外商直接投资情况.html
│   └── 预期寿命.html
├── FDI.py
└── world_health.ipynb
```

其中 `./visualization/data/` 是可视化所用到的数据，不仅包括我们绘图所需的数据，包括对外直接投资 `FDI*.csv`、健康相关数据 `LE*.csv` 和 `UFMR*.csv` 等，还包括中英对照表 `country_ce.json`、以及国家名的同义对照表 `syno_dict.json` 等工具数据。

`obor_raw_plot/` 和 `wh_raw_plot/` 两个目录是用 R 生成的原始数据集变化情况，其中一带一路参与国家以加粗线绘制。

`mytool.ipynb` 为工具和测试用 notebook，用于生成工具 json 和进行原型开发测试。

FDI.py 为对外直接投资可视化脚本，出于易用性，其中 `render()` 函数中给出的文件名，在得到成品文件后稍后手动更改为中文。

`world_health.ipynb` 为世界卫生健康相关数据可视化脚本，前两个 cell 分别用于绘制世界国家预期寿命和 5 岁以下死亡率，第三个 cell 尝试将不同的性别绘制在同一张图中，但是由于 `timeline` 和 `gender` 两个尺度只能分开调整，所以在时间纵向对比时并不方便，我们将结果绘制为三个图构成的 Page Echarts 图。

`./visualization/out/` 是可视化的文件，成品文件名已经更改，相对清楚。注意其中外商直接投资情况-filled.html 为利用算法填充部分缺失数据之后的 FDI 图像。

3.6.3 流程

以 FDI（对外直接投资）为例，我们讲述项目中使用的 `pyecharts` 可视化方法，相对其他几个可视化工作，其中使用了对数化、相对复杂，故说明后其余同理。

```
import pandas as pd                                # 数据分析组件
import json                                         # 用于导入工具 json
from pyecharts import options as opts              # 用于调整 pyecharts 图的属性
from pyecharts.charts import Timeline, Map          # 选取 pyecharts 基本类型
from pyecharts.globals import ThemeType            # 选取 pyecharts 主题
import numpy as np                                  # python 数值计算工具

tl = Timeline(init_opts=opts.InitOpts(
    theme=ThemeType.INFOGRAPHIC,
    bg_color='white',
    page_title=' 外商直接投资情况'
))                                                  # 生成 timeline 图结构
with open("./data/country_ce.json", 'r', encoding='utf-8') as f:
    ce_dict = json.load(f)                          # 导入国家名称中英文对照表

df = pd.read_csv('./FDI_filled_m.csv')              # 生成 dataframe
df.iloc[:, 3] = df.iloc[:, 3].apply(np.log1p)       # 将数值列对数化
for year in range(2003, 2019+1):                    # 循环添加不同年份的数据到 timeline 图中
    map = (
        Map()                                       # 生成一个年份的地图
        .add(df.columns.tolist()[-1]+"（对数值，原单位：百万美元）", # 设定图层名
            [[ce_dict[row['国家']], row[3]]         # 读入数据，使用 dataframe 方法进行筛选
             for _, row in df[df.iloc[:, 0] == year].iterrows()],
        maptype="world",                           # 设定为世界地图
        is_map_symbol_show=False,                   # 不描点
    )
    .set_series_opts(label_opts=opts.LabelOpts(is_show=False)) # 在地图中不显示对应国家的数值
```

```

.set_global_opts(
    title_opts=opts.TitleOpts(title=f"{year}年外商直接投资情况"), # 设定当前页的标题
    visualmap_opts=opts.VisualMapOpts(
        max_=df[df.iloc[:, 0] == year].iloc[:, 3].max(), # 重设图例范围
        toolbox_opts=opts.ToolboxOpts(), # 打开工具箱组件, 便于后续使用鼠标调节
    )
)
tl.add(map, f"{year}年") # 将当前图层加入 timeline 结构中
tl.render("./out/vis.html") # 生成临时文件

```

4 总结

4.1 分析结果

```
ci_csv %>% filter(`max(ci.sc)`<0) %>% group_by(国家) %>% nest() %>% .[[" 国家"]]
```

```
## [1] "哈萨克斯坦" "斯洛文尼亚" "拉脱维亚" "黑山"
```

```
ci_csv %>% filter(`min(ci.sc)`>0) %>% group_by(国家) %>% nest() %>% .[[" 国家"]]
```

```
## [1] "新加坡" "格鲁吉亚" "白俄罗斯"
```

```
ci_csv %>% .[["median(ci.sc)"]] %>% mean()
```

```
## [1] -0.03983766
```

可见, 在一带一路的参与国家中, 婴儿死亡率相比预期降低 ($P < 0.10$) 的国家共有 4 个. 婴儿死亡率相比预期升高 ($P < 0.10$) 的国家共有 3 个. 平均而言, 一带一路能够额外降低婴儿死亡率的对数约 0.04.

```
cii_csv %>% filter(`max(ci.sc)`<0) %>% group_by(国家) %>% nest() %>% .[[" 国家"]]
```

```
## [1] "缅甸" "文莱" "巴林" "也门共和国" "叙利亚"
```

```
## [6] "阿塞拜疆" "斯洛文尼亚" "匈牙利"
```

```
cii_csv %>% filter(`min(ci.sc)`>0) %>% group_by(国家) %>% nest() %>% .[[" 国家"]]
```

```
## [1] "印度尼西亚"
```

```
cii_csv %>% .[["median(ci.sc)"]] %>% mean()
```

```
## [1] -0.4027635
```

与预期不符的是，在一带一路的参与国家中，中国对当地的投资相比预期降低 ($P < 0.10$) 的国家共有 8 个。中国对当地的投资相比预期升高 ($P < 0.10$) 的国家共有 1 个。平均而言，参与一带一路反而额外降低中国对当地的投资的对数约 0.40。

根据常识，投资 (Y) 对经济发展水平 (Z) 的平均因果作用是正的，而经济发展水平 (Z) 对健康水平 (W) 的平均因果作用也是正的。因此，根据我们的模型，在相同的经济发展水平下，参与一带一路能够相比预期增加沿线国家的国民健康水平，或者狭义来说，降低婴儿死亡率。从这一方面来看，一带一路对沿线国家经济以外的影响，还有待更深的评估。

4.2 不足和展望

我们的报告最显著的不足之处是将不同国家的结论组合的方式显得过于随意，仅仅是计算每个国家的效应然后求平均，没有考虑到国家和国家的权重问题。类似地，在计算投资额时，可以考虑除去国家的经济总量，以反映中国投资占比占该国家 GDP 的比例。进一步地，一组国家总效应的置信区间并不必然是分别的效应的置信区间的函数。然而，进一步研究这个问题需要更多的数学细节，并超过了本项目的范围。

参考文献

- [1] BARRETT M. ggdag: Analyze and Create Elegant Directed Acyclic Graphs[M]. 2021.
- [2] PEARL J, GLYMOUR M, JEWELL N P. Causal inference in statistics: a primer[M]. Wiley, 2019.
- [3] KOWARIK A, TEMPL M. Imputation with the R Package VIM[J]. Journal of Statistical Software, 2016, 74(7): 1–16.
- [4] VAN BUUREN S, GROOTHUIS-OUDSHOORN K. mice: Multivariate Imputation by Chained Equations in R[J]. Journal of Statistical Software, 2011, 45(3): 1–67.
- [5] SCHAFER J L. Analysis of incomplete multivariate data[M]. Chapman & Hall/CRC, 1997.
- [6] DOUDCHENKO N, IMBENS G W. Balancing, Regression, Difference-In-Differences and Synthetic Control Methods: A Synthesis[R]. Working Paper Series, 22791, National Bureau of Economic Research, 2016.
- [7] ABADIE A, GARDEAZABAL J. The Economic Costs of Conflict: A Case Study of the Basque Country[J]. The American Economic Review, American Economic Association, 2003, 93(1): 113–132.
- [8] CHERNOZHUKOV V, WÜTHRICH K, ZHU Y. An Exact and Robust Conformal Inference Method for Counterfactual and Synthetic Controls[J]. Journal of the American Statistical Association, Taylor & Francis, 2021, 0(ja): 1–44.

- [9] WICKHAM H. Advanced R[M]. CRC Press, 2019.
- [10] WICKHAM H, GROLEMUND G. R for Data Science: Import, Tidy, Transform, Visualize, and Model Data[M]. 第 1 版. Paperback; O'Reilly Media, 2017.
- [11] DONOHO D. 50 Years of Data Science[J]. Journal of Computational and Graphical Statistics, Taylor & Francis, 2017, 26(4): 745–766.
- [12] WICKHAM H. Tidy data[J]. The Journal of Statistical Software, 2014, 59(10).
- [13] WICKHAM H, AVERICK M, BRYAN J, 等. Welcome to the tidyverse[J]. Journal of Open Source Software, 2019, 4(43): 1686.
- [14] LI D, MEI H, SHEN Y, 等. ECharts: A declarative framework for rapid construction of web-based visualization[J]. Visual Informatics, 2018, 2(2): 136–146.